PHÂN LỚP DỮ LIỆU BỆNH ĐÁI THÁO ĐƯỜNG

Using the Pima Indians Diabetes Dataset

I

PHÂN TÍCH VỀ BÀI TOÁN

1.TỔNG QUAN VỀ BÀI TOÁN

Bệnh đái tháo đường

Là một rối loạn chuyển hóa mãn tính đặc trưng bởi tình trạng tăng đường huyết kéo dài do cơ thể không sản xuất đủ insulin hoặc không sử dụng insulin hiệu quả.

Mức độ phổ biến

Theo thống kê của WHO, số người mắc bệnh trên toàn cầu đã vượt quá 500 triệu và vẫn đang tiếp tục gia tăng, đặc biệt tại các quốc gia đang phát triển.

Tầm quan trọng của việc phát hiện sớm

Phát hiện sớm và dự đoán được nguy cơ mắc bệnh có vai trò quan trọng trong việc phòng ngừa và kiểm soát đái tháo đường

Bộ dữ liệu Pima Indians Diabetes

Đây là tập dữ liệu kinh điển trong lĩnh vực học máy y sinh, bao gồm thông tin lâm sàng của phụ nữ người Mỹ bản địa Pima, với các biến số như số lần mang thai, nồng độ glucose huyết tương, huyết áp, độ dày lớp da, insulin, BMI, chỉ số di truyền và tuổi. Việc lựa chọn bộ dữ liệu này không chỉ giúp chuẩn hóa quy trình phân tích mà còn tạo điều kiện thuận lợi cho việc so sánh với các nghiên cứu trước đó.

2.MỤC TIÊU BÀI TOÁN

Mục tiêu chính

Xây dựng và so sánh các mô hình

Xây dựng và so sánh các mô hình học máy có giám sát để dự đoán khả năng mắc bệnh của bệnh nhân dựa trên các chỉ số sinh lý.

xử lý dữ liệu chuyên sâu

Thực nghiệm quy trình tiền xử lý dữ liệu chuyên sâu, bao gồm xử lý các giá trị 0 phi lý và so sánh hiệu quả giữa các phương pháp chuẩn hóa.

Tối ưu hóa các thuật toán

Tối ưu hóa các thuật toán phân lớp thông qua việc tinh chỉnh siêu tham số để đạt được độ chính xác và khả năng tin cậy cao nhất trong chẩn đoán y tế.

3.MỤC TIÊU NGHIÊN CỨU

Dạng bài toán

Đây là bài toán Phân lớp nhị phân thuộc lĩnh vực học máy có giám sát. Mô hình sẽ học ánh xạ từ không gian đặc trưng đa chiều của bệnh nhân sang một trong hai trạng thái chẩn đoán duy nhất.

Thành phần

Dữ liệu đầu vào

1.Pregnancies: Số lần mang thai.
2.Glucose: Nồng độ đường trong máu
3.BloodPressure: Huyết áp tâm trương.
4.SkinThickness: Độ dày nếp gấp da cơ tam đầu.
5.Insulin: Nồng độ insulin trong huyết thanh.
6.BMI: Chỉ số khối cơ thể.
7.DiabetesPedigreeFunction: Chỉ số di truyền về nguy cơ mắc bệnh.
8.Age: Tuổi của bệnh nhân.

Dữ liệu đầu ra

*Outcome nhận giá trị nhị phân
0: Không mắc đái tháo đường
1: Mắc đái tháo đường

4.Câu hỏi nghiên cứu và thách thức

Câu hỏi nghiên cứu:

- Việc áp dụng StandardScaler hay MinMaxScaler sẽ mang lại hiệu suất tốt hơn cho các mô hình nhạy cảm với khoảng cách như SVM và KNN?
- Mô hình nào trong Logistic Regression, Decision Tree, hay Naive Bayes có khả năng cân bằng tốt nhất giữa độ nhạy và độ chính xác?

Thách thức:

- Dữ liệu nhiễu: Xử lý các giá trị bằng 0 tại các cột sinh lý như Insulin hay SkinThickness vốn không thể tồn tại trong thực tế y khoa.
- Mất cân bằng lớp: Tỷ lệ người không mắc bệnh cao hơn người mắc bệnh, đòi hỏi mô hình không được thiên kiến về lớp đa số.

5.Độ đo đánh giá

Nhóm sử dụng bộ độ đo đa diện để đánh giá mô hình một cách khách quan nhất:

- **Accuracy:** Đánh giá tổng quát tỉ lệ dự đoán đúng.
- **Precision:** Đảm bảo giảm thiểu việc chẩn đoán nhầm người khỏe mạnh thành người có bệnh.
- **Recall**: Quan trọng nhất trong y tế, nhằm đảm bảo không bỏ sót bất kỳ bệnh nhân nào thực sự mắc bệnh.
- **F1-Score**: Giá trị trung bình điều hòa, giúp đánh giá hiệu suất tổng thể khi dữ liệu có sự mất cân bằng lớp.

II

PHƯƠNG PHÁP VÀ QUÁ TRÌNH THỬ NGHIỆM

1.Phương pháp nghiên cứu

- Xây dựng Pipeline xử lý: Tích hợp các bước tiền xử lý và huấn luyện. Việc này đảm bảo dữ liệu được làm sạch và chuẩn hóa một cách đồng nhất trước khi đưa vào mô hình.
- Chiến lược xử lý dữ liệu thiếu: Sử dụng **SimpleImputer** thay thế các giá trị 0 phi lý bằng trung vị hoặc trung bình.
- Thử nghiệm 3 phương pháp chuẩn hóa: Nhóm triển khai đánh giá song song trên 3 trạng thái dữ liệu:

1. Dữ liệu thô.
2. Chuẩn hóa về đoạn [0, 1] bằng **MinMaxScaler**.
3. Chuẩn hóa về phân phối chuẩn ($\mu=0$, $\sigma=1$) bằng **StandardScaler**.

- Kiểm chuẩn và tối ưu hóa:
  - Sử dụng phương pháp **Hold-out** để chia tập Train/Test theo tỉ lệ 7/3.
  - Dùng **GridSearchCV** và **Cross-validation** để tìm bộ tham số tối ưu

2. Quá trình thực nghiệm cụ thể

2.1. Thiết lập thực nghiệm

Công cụ & Thư viện:

- Ngôn ngữ: Python.
- Xử lý dữ liệu: Pandas, Numpy.
- Học máy: Scikit-learn.
- Trực quan hóa: Matplotlib, Seaborn.

Chiến lược đánh giá:

- Phân chia dữ liệu: Hold-out tỉ lệ 7/3.
- Kiểm chứng: 10-fold Cross-validation trên tập huấn luyện.
- Mục tiêu: Đảm bảo tính ổn định của tham số và kiểm soát hiện tượng Overfitting.

2. Quá trình thực nghiệm cụ thể

2.2. Tiền xử lý dữ liệu

Dựa trên đặc thù của hai bộ dữ liệu Iris và Pima Indians Diabetes, các kỹ thuật chuẩn hóa sau đã được áp dụng để đưa các đặc trưng về cùng một thang đo:

- **Dữ liệu thô**: Giữ nguyên giá trị gốc.
- **Min-Max Scaling**: Chuyển đổi dữ liệu về khoảng [0, 1].
- **Standard Scaling**: Chuẩn hóa dữ liệu với trung bình bằng 0 và độ lệch chuẩn bằng 1.
- **Xử lý giá trị thiếu cho bộ dữ liệu Pima**: Các giá trị 0 phi lý tại các cột Glucose, BloodPressure, BMI... được thay thế bằng giá trị trung vị (Median) của cột đó.

2. Quá trình thực nghiệm cụ thể

2.3. Các mô hình huấn luyện

Nhóm triển khai 6 thuật toán phổ biến với tham số mặc định để thiết lập ngưỡng so sánh:

1. Logistic Regression: Phân loại tuyến tính nhị phân.
2. Linear Discriminant Analysis: Phân tách lớp qua không gian con tối ưu.
3. K-Neighbors: Phân loại dựa trên khoảng cách k láng giềng.
4. Decision Tree: Cây quyết định dựa trên chỉ số Gini/Entropy.
5. Gaussian Naive Bayes: Dựa trên định lý Bayes với giả định các đặc trưng độc lập.
6. Support Vector Machine: Tối ưu hóa siêu phẳng để phân tách dữ liệu.

2. Quá trình thực nghiệm cụ thể

2.4.Tinh chỉnh tham số

Hai mô hình KNN và SVM được lựa chọn để thực hiện tối ưu hóa bằng công cụ GridSearchCV:

- SVM: Tinh chỉnh tham số C và gamma với các Kernel khác nhau (RBF, Linear).
- KNN: Tìm kiếm giá trị k tối ưu trong khoảng từ 1 đến 20.

III

KẾT QUẢ VÀ ĐÁNH GIÁ

1.Hiệu suất của các mô hình Baseline

Bảng dưới đây so sánh **Accuracy** của các mô hình trên tập Test khi sử dụng dữ liệu thô:

Model	**Model**	**Model**	**Model**	**Model**	**Model**	**Model**	**TN**	**F1-score**
Decision Tree	1	718.614.719	726.380.154	46	30	35	120	585.987.261
LR	783.950.617	761.904.762	772.990.915	44	18	37	132	615.384.615
Naive Bayes	777.777.778	70.995.671	772.955.975	44	30	37	120	567.741.935
SVM	783.950.617	770.562.771	771.139.064	44	16	37	134	624.113.475
Linear Discrimination	74.375	755.458.515	761.390.636	40	17	39	133	588.235.294
K-Neighbors	675	720.524.017	712.403.913	46	31	33	119	58.974.359

1.Hiệu suất của các mô hình Baseline

Dựa vào kết quả thực nghiệm trên dữ liệu thô, chúng ta có thể rút ra một số nhận xét quan trọng về hiệu suất của các thuật toán:

- Mô hình dẫn đầu về hiệu suất: Support Vector Machine (SVM) và Logistic Regression (LR) là hai mô hình cho kết quả dự đoán tổng thể tốt nhất. Cụ thể, SVM đạt độ chính xác trên tập kiểm tra (Test Accuracy) cao nhất là 0.770, theo sát là LR với 0.761. Xét về chỉ số F1-score, SVM và LR cũng lần lượt dẫn đầu với 0.624 và 0.615. Điều này cho thấy đối với tập dữ liệu y tế này ở dạng thô, các mô hình có khả năng phân tách tuyến tính đang hoạt động tương đối ổn định và cân bằng tốt giữa Precision và Recall.

1.Hiệu suất của các mô hình Baseline

- Hiện tượng Overfitting ở Decision Tree: Một điểm đáng lưu ý là mô hình Decision Tree đạt độ chính xác tuyệt đối 1.0 trên tập Validation, nhưng lại sụt giảm mạnh xuống chỉ còn 0.718 trên tập Test. Đây là minh chứng rõ nét cho hiện tượng overfitting, khi mô hình học thuộc lòng các nhiễu trong tập huấn luyện nhưng lại mất đi khả năng khái quát hóa trên dữ liệu mới.

1.Hiệu suất của các mô hình Baseline

- Hạn chế của các mô hình dựa trên khoảng cách và xác suất: K-Neighbors (KNN) và Naive Bayes có hiệu suất thấp hơn, với Test Accuracy lần lượt là 0.720 và 0.709. Đối với KNN, việc dữ liệu thô có sự chênh lệch lớn về thang đo giữa các đặc trưng (ví dụ: Insulin có thể lên tới hàng trăm, trong khi DiabetesPedigreeFunction chỉ dao động dưới 3) đã làm sai lệch việc tính toán khoảng cách Euclidean, dẫn đến kết quả phân lớp chưa tối ưu.

2.Tác động của việc chuẩn hóa dữ liệu

Model	Validation Accuracy	Test Accuracy	Mean Kfold Accuracy	TP	FP	FN	TN	F1-score
Decision Tree	8.125	711.790.393	703.284.416	68	55	11	95	673.267.327
LR	7.625	737.991.266	751.991.614	54	35	25	115	642.857.143
Naive Bayes	6.875	72.489.083	752.061.495	48	32	31	118	603.773.585
	6.875	729.257.642	752.061.495	48	31	31	119	607.594.937
SVM	783.950.617	753.246.753	765.513.627	41	17	40	133	589.928.058
	75.308.642	731.601.732	748.567.435	57	38	24	112	647.727.273
Linear Discrimination	73.125	751.091.703	766.946.191	41	19	38	131	589.928.058
K-Neighbors	757.756.813	733.624.454	757.756.813	44	26	35	124	590.604.027

2.Tác động của việc chuẩn hóa dữ liệu

Việc áp dụng các kỹ thuật chuẩn hóa (Min/Max Scaling và Standard Scaling) đã làm thay đổi đáng kể cục diện hiệu suất của các mô hình. Phân tích từ bảng kết quả cho thấy những tác động đa chiều của bước tiền xử lý này đối với từng thuật toán:

- Sự cải thiện của mô hình nhạy cảm với khoảng cách: Đúng với lý thuyết, mô hình K-Neighbors (KNN) đã ghi nhận sự tăng trưởng về Test Accuracy từ 0.720 trên dữ liệu thô lên 0.733. Việc đưa các đặc trưng về cùng một thang đo giúp KNN tính toán khoảng cách láng giềng một cách công bằng, không bị lấn át bởi các biến có giá trị lớn như Insulin hay Glucose.

2.Tác động của việc chuẩn hóa dữ liệu

- Sự đánh đổi giữa Accuracy và khả năng nhận diện lớp thiểu số (F1-score): Một điểm rất đáng chú ý là mặc dù Test Accuracy của Decision Tree giảm từ 0.726 xuống 0.711, nhưng chỉ số F1-score lại tăng vọt từ 0.585 lên mức 0.673. Nhìn vào ma trận nhầm lẫn (Confusion Matrix), số lượng ca bị dự đoán sót (False Negative) của Decision Tree giảm mạnh xuống chỉ còn 11 ca. Trong bài toán y tế, việc giảm thiểu việc bỏ sót bệnh nhân quan trọng hơn nhiều so với việc duy trì độ chính xác tổng thể. Mô hình Logistic Regression cũng ghi nhận xu hướng tương tự khi F1-score tăng lên 0.642.

2.Tác động của việc chuẩn hóa dữ liệu

Biến động hiệu suất giữa các phương pháp chuẩn hóa (Min/Max vs Standard): Bảng dữ liệu phản ánh rõ sự khác biệt khi áp dụng hai kỹ thuật chuẩn hóa khác nhau lên cùng một mô hình:

- Với Naive Bayes: Cả hai phương pháp chuẩn hóa cho kết quả tương đối ổn định và bám sát nhau (Test Accuracy đạt 0.724 và 0.729, F1-score ở mức 0.603 và 0.607).

- Với SVM: Sự khác biệt thể hiện rất rõ rệt. Một phương pháp chuẩn hóa giúp SVM đạt Test Accuracy cao hơn (0.753) nhưng F1-score lại khá thấp (0.589), đi kèm với tỷ lệ bỏ sót bệnh nhân cao (FN = 40). Ngược lại, phương pháp chuẩn hóa thứ hai tuy làm Test Accuracy giảm nhẹ xuống 0.731, nhưng lại đẩy mạnh F1-score lên 0.647 và giảm đáng kể số ca FN xuống còn 24. Điều này minh chứng cho việc không gian dữ liệu sau chuẩn hóa đã ảnh hưởng trực tiếp đến việc định hình siêu phẳng phân cách của SVM. Tùy thuộc vào mục tiêu y tế (ưu tiên độ chính xác toàn cục hay ưu tiên độ nhạy), chúng ta sẽ có cơ sở vững chắc để chọn ra phương pháp chuẩn hóa phù hợp nhất.

IV

HƯỚNG CẢI TIẾN MÔ HÌNH

Dựa trên kết quả thực nghiệm, mặc dù các mô hình đã đạt được mức hiệu suất nhất định, tỷ lệ dự đoán sai (đặc biệt là False Negative) vẫn còn tồn tại. Trong bối cảnh y tế, việc bỏ sót bệnh nhân mắc bệnh là rủi ro lớn nhất. Do đó, để nâng cao độ tin cậy và khả năng triển khai thực tế của mô hình, các hướng cải tiến sau được đề xuất:

- Xử lý mất cân bằng lớp: Dù chuẩn hóa giúp cải thiện F1-score, FN vẫn còn cao (DT: 11 ca, SVM: 24 ca) do chênh lệch mẫu. Giải pháp: Áp dụng SMOTE để cân bằng dữ liệu, giúp mô hình học ranh giới quyết định chính xác hơn.

- Đánh giá thuật toán: SVM và Logistic Regression là hai mô hình ổn định và cho hiệu quả phân lớp tốt nhất trên bộ dữ liệu y tế đa biến này.

- Kiểm chuẩn & Tổng quát hóa: Kết hợp Hold-out và K-Fold Cross-validation để đánh giá khách quan và nhận diện sớm hiện tượng Overfitting (điển hình ở Decision Tree).

- Tối ưu tham số: Sử dụng GridSearchCV để thiết lập ngưỡng tin cậy vững chắc trước khi đưa mô hình vào hỗ trợ chẩn đoán lâm sàng.

THANK YOU